



Predicting Answer Correctness from Top-10 Probability Curves


COMPUTATIONAL SEMANTICS – FINAL PROJECT

Özgür Aslan

Veri Kümesi

Turkish GSM8K veri kümesinden 250 train ve 250 test sorusu seçildi. Her soru için **Qwen3-4B** ile 10 cevap üretildi.

Yalnızca modelin hem doğru hem de yanlış cevap ürettiği sorular tutuldu. (**karma soru**)



Train: 68 / 250

karma soru

Test: 64 / 250

karma soru


Toplam: 132 / 500

karma soru, 1320 cevap


Soruların Yorumlanması (Dengesizler)

Sınıf dengesizliği olduğunda (örn. 9 doğru / 1 yanlış), Ayrım güvenilir hale gelir.

Yeşil çizgiler doğru, **kırmızı çizgiler** yanlış cevaplara aittir.



Soruların Yorumlanması (Dengeliler)



Bu soruda **5 doğru ve 5 yanlış** cevap bulunmaktadır. Dengeli sınıf dağılımı karşılaştırmayı kolaylaştırır.

Modelleme Sonuçları

Model	Accuracy	F1	ROC-AUC
XGBoost	0.5578	0.5928	0.5623
CatBoost	0.5750	0.6233	0.6093
Gradient Boosting	0.5734	0.6106	0.6151
Random Forest	0.5781	0.6143	0.6073
LightGBM	0.5578	0.6053	0.5875

Teşekkürler

